Influencia de la presencia humana y la densidad colonial en la respuesta a las perturbaciones de la gaviota patiamarilla

Rocío Calderón Madrid

25 de octubre de 2026

1. Introducción

El aumento de las actividades recreativas en espacios naturales ha incrementado la necesidad de comprender los efectos de la presencia humana sobre la fauna silvestre y de compatibilizar el uso recreativo del medio con la conservación de la biodiversidad (Anderson & Keith, 1980; Boyle & Samson, 1985; Hill et al., 1997; Ikuta & Blumstein, 2003; Stankowich & Blumstein, 2005). Las perturbaciones humanas pueden alterar el comportamiento de los animales, por lo que resulta fundamental identificar los factores que condicionan su respuesta (Blumstein, 2006; Carney & Sydeman, 1999; Fernández-Juricic et al., 2004).

Uno de los indicadores utilizados para evaluar esta respuesta es la distancia de inicio de vuelo (*flight initiation distance*, FID), definida como la distancia a la que un ave huye ante la aproximación de una persona. Este parámetro permite estudiar la sensibilidad de las aves a las perturbaciones (Blumstein et al., 2003; Burger & Gochfeld, 1991) y establecer distancias de seguridad para minimizar sus efectos (Blumstein, 2003; Blumstein et al., 2003; Finney et al., 2005; Geist et al., 2005). No obstante, la FID puede variar entre poblaciones y depender de factores como la exposición previa a las personas y las características del entorno.

La frecuencia de las visitas humanas puede favorecer la habituación de los animales, reduciendo su distancia de inicio de vuelo (Ikuta & Blumstein, 2003; McClung et al., 2004). Asimismo, la densidad de individuos puede influir en su comportamiento y en los costes asociados a la huida (Anderson & Keith, 1980; Carney & Sydeman, 1999). En este contexto, Martínez-Abraín et al. (2008) analizaron estos factores en colonias de gaviota patiamarilla (*Larus michahellis*) y observaron una relación negativa entre la FID, el número de visitantes y la densidad de gaviotas nidificantes.

El objetivo de este trabajo es ampliar el análisis realizado por Martínez-Abraín et al. (2008) mediante un estudio estadístico más exhaustivo de la relación entre el número de visitantes, la densidad de gaviotas nidificantes y la FID. Se pretende profundizar en la relación entre estas variables y la respuesta conductual de la gaviota patiamarilla, explorando diferentes enfoques estadísticos para obtener una comprensión más completa de los factores asociados a la FID.

2. Materiales y métodos

2.1. Diseño del estudio y descripción de los datos

Los datos proceden de Martínez-Abraín et al. (2008) e incluyen 15 colonias de gaviota patiamarilla distribuidas por el litoral mediterráneo ibérico y francés, la costa atlántica ibérica y el norte de África. En tres colonias (Cíes, Ons y Columbretes) se diferenciaron zonas visitadas y no visitadas,

consideradas unidades independientes, lo que dio lugar a 18 unidades de estudio.

La distancia de inicio de vuelo (FID) se midió mediante la aproximación de observadores a velocidad constante, utilizando un telémetro (Geist et al., 2005). Para evitar la falta de independencia, se excluyeron las aves que huían como consecuencia del vuelo de otro individuo (Roberts & Evans, 1993). Las 1081 mediciones se resumieron mediante la FID media de cada unidad. Las variables explicativas fueron el número medio de visitantes y la densidad de parejas reproductoras por unidad de superficie, obtenidos de datos propios o de informes de las administraciones regionales. Aunque la mayoría de las colonias se muestrearon durante la incubación, las cuatro colonias francesas se visitaron al final de la temporada reproductiva. A las 11 colonias sin visitas regulares se les asignó un valor de dos visitantes para evitar ceros. Además, se definió el factor *visitada*, con niveles No ($V_i = 2$) y Sí ($V_i > 2$), como alternativa a la variable continua. Por todo ello, el estudio tiene un diseño observacional, transversal y prospectivo.

2.2. Análisis exploratorio

El análisis exploratorio tiene como objetivo describir la distribución de la variable respuesta, identificar las transformaciones que linealizan su relación con las covariables y anticipar posibles no linealidades o interacciones que condicionarán la elección del modelo estadístico.

2.2.1. Distribución de la variable respuesta

La variable respuesta, Y_i, es la FID media de la colonia i, expresada en metros. Presenta una asimetría a la derecha (coeficiente de asimetría de 0,78), debida a unas pocas colonias con distancias superiores a 60 m (Figura A1 a).Tanto la raíz cuadrada como el logaritmo reducen esa asimetría (Figura A1 b, c), lo que respalda las dos estrategias de modelización consideradas: un modelo lineal sobre $\sqrt{Y_i}$, como en Martínez-Abraín et al. (2008), y un modelo lineal generalizado con enlace logarítmico, que permite modelizar Y_i mediante una distribución Gamma.

2.2.2. Relación entre la FID y las covariables

Las Figuras A2 y A3 muestran la relación entre la FID y cada covariable en la escala original (panel a) y transformada (panel b). El número de visitantes presenta 11 colonias en el valor 2 y ningún dato entre 154 y 2643 visitantes, por lo que el suavizado LOESS en escala original muestra oscilaciones. La transformación logarítmica linealiza su relación con la respuesta ($r = -0{,}61$ para $\sqrt{Y}$ y $r = -0{,}64$ para $\log Y$) y lo identifica como la covariable con mayor asociación marginal. La densidad es asimétrica y la raíz cuadrada mejora su linealidad, aunque su asociación marginal es débil ($r = -0{,}23$ para $\sqrt{Y}$ y $r = -0{,}18$ para $\log Y$). La correlación entre ambas covariables transformadas es moderada ($r = -0{,}40$), por lo que no hay colinealidad elevada y se incluyen conjuntamente. No se incluye su interacción, ya que con $n = 18$ y solo siete colonias visitadas, todas de baja densidad, no podría estimarse de forma fiable.

2.3. Estrategia de modelización

Se adoptó una estrategia secuencial. Primero se eligió la distribución de la respuesta y la codificación de los visitantes, comparando el modelo lineal (LM) sobre $\sqrt{Y}$ de Martínez-Abraín et al. (2008) con el modelo lineal generalizado (GLM) con distribución Gamma, ambos con los visitantes como variable continua y como factor *visitada*. Después se evaluó la linealidad de los efectos mediante modelos aditivos generalizados (GAM) con las covariables en escala original. Por último, el mejor GAM se comparó con el modelo seleccionado en la primera etapa, y el modelo final seleccionado se estimó por máxima verosimilitud y mediante inferencia bayesiana.

2.3.1. Modelos estadísticos

En todos los modelos, las covariables son el número de visitantes, V_i, y la densidad de parejas reproductoras, D_i, de cada colonia ($i = 1, \ldots, 18$). Cuando los visitantes se incluyen como variable categórica, se utiliza el factor *visitada*, representado mediante el indicador W_i.

Modelo lineal (LM). Sea Y_i la FID media de la colonia $i = 1, \ldots, 18$, expresada en metros. De acuerdo con el análisis exploratorio, se aplica una transformación de raíz cuadrada para reducir la asimetría de la variable respuesta. Se asume que la variable transformada sigue una distribución normal:

$$\sqrt{Y_i} \sim N(\mu_i, \sigma^2), \qquad E(\sqrt{Y_i}) = \mu_i, \qquad \mathrm{Var}(\sqrt{Y_i}) = \sigma^2, \qquad i = 1, \ldots, 18. \tag{1}$$

donde μ_i es la media de la variable respuesta transformada y σ^2 es la varianza residual, constante para todas las colonias. La media se expresa mediante el predictor lineal, de modo que $\mu_i = \eta_i$. Cuando el número de visitantes se incluye como variable continua, el predictor lineal es

$$\eta_i = \beta_0 + \beta_1 \log V_i + \beta_2 \sqrt{D_i}, \tag{2}$$

mientras que, cuando se incluye como variable categórica mediante el indicador W_i, es

$$\eta_i = \beta_0 + \beta_1 W_i + \beta_2 \sqrt{D_i}, \tag{3}$$

donde β_0 es el intercepto y β_1 y β_2 son los coeficientes asociados a las covariables.

Modelo lineal generalizado Gamma (GLM). A diferencia del modelo lineal, en este caso se asume que la FID media, Y_i, sigue una distribución Gamma:

$$Y_i \sim \mathrm{Gamma}(\mu_i, \phi), \qquad E(Y_i) = \mu_i, \qquad \mathrm{Var}(Y_i) = \phi \mu_i^2, \qquad i = 1, \ldots, 18, \tag{4}$$

donde μ_i es la FID media esperada en la colonia i y ϕ es el parámetro de dispersión, común a todas las colonias. Para relacionar la media con las covariables se utiliza una función de enlace logarítmica:

$$\log(\mu_i) = \eta_i \tag{5}$$

Esta función de enlace garantiza predicciones positivas y permite interpretar los efectos de las covariables de forma multiplicativa. La estructura del predictor lineal es la misma que en el modelo lineal, tanto cuando el número de visitantes se incluye como variable continua (ecuación 2) como cuando se incorpora mediante el indicador categórico W_i (ecuación 3). En ambos casos, la diferencia entre los modelos radica en la distribución de la variable respuesta y en la función de enlace empleada.

Modelo aditivo generalizado (GAM). Se mantienen la distribución Gamma y el enlace logarítmico del GLM, y se sustituyen los efectos lineales por funciones suavizadas de las covariables en su escala original:

$$\eta_i = \beta_0 + f_1(V_i) + f_2(D_i), \tag{6}$$

donde f_1 y f_2 representan los efectos potencialmente no lineales del número de visitantes y la densidad, respectivamente, mediante *thin plate regression splines*. El grado de suavizado de cada

spline se cuantificó mediante los grados de libertad efectivos (*edf*). Para definir la dimensión de las bases, se partió de $k = 5$ para ambas covariables y se redujo este valor hasta situarlo ligeramente por encima de edf + 1, siempre que la devianza explicada no disminuyera apreciablemente. Así se limita la complejidad de las bases sin comprometer el ajuste. Cuando los *edf* fueron próximos a 1, la covariable correspondiente se incorporó como término lineal.

2.3.2. Estimación, validación y selección

Los LM y GLM se ajustaron mediante máxima verosimilitud, mientras que los GAM se ajustaron mediante máxima verosimilitud restringida (REML) con el paquete `mgcv` (Wood, 2025) de R (R Core Team, 2024). La evaluación de los modelos se basó en la inspección visual de los gráficos de diagnóstico de los residuos y en la detección de observaciones influyentes mediante la distancia de Cook. En los LM, la inspección visual de los residuos se complementó con la prueba de Kolmogorov-Smirnov frente a una distribución t de Student con 14 grados de libertad y con la prueba de Levene para evaluar la homogeneidad de varianzas, implementada en el paquete `lawstat` (Gastwirth et al., 2023). En los GAM, se comprobó la suficiencia de la dimensión de las bases y se examinó la concurvidad entre los *splines*.

La selección del modelo se basó en dos criterios complementarios. En primer lugar, se utilizó el criterio de información de Akaike (AIC), que permite comparar modelos ajustados a una misma variable respuesta. Para comparar el AIC del LM, cuya respuesta es $\sqrt{Y}$, con el de los modelos ajustados sobre la escala original de la FID, se aplicó la corrección correspondiente al jacobiano de la transformación:

$$J = 2\sum_{i=1}^{n} \log\left(2\sqrt{Y_i}\right). \tag{7}$$

Esta corrección es común a los modelos que utilizan la respuesta transformada y, por tanto, no modifica las diferencias de AIC entre ellos. En segundo lugar, la capacidad predictiva se evaluó mediante el error cuadrático medio de predicción (MSEP), calculado por validación cruzada dejando una colonia fuera (LOOCV). En los LM, tanto los valores observados como las predicciones se elevaron al cuadrado para expresar el error en m^2 y facilitar su comparación con el obtenido para los GLM. La validación cruzada se implementó con el paquete `boot` (Canty & Ripley, 2025) para los modelos compatibles. Dado que este paquete no admite directamente los GAM, se programó una función equivalente para estos modelos.

El modelo seleccionado se ajustó también mediante inferencia bayesiana con JAGS, utilizando el paquete jagsUI (Kellner, 2026). Se especificaron distribuciones *a priori* vagas para minimizar su influencia sobre la inferencia. Se ejecutaron tres cadenas de 12000 iteraciones, descartando las 2000 primeras como periodo de calentamiento y conservando una de cada diez iteraciones restantes. La convergencia se evaluó mediante el estadístico de Gelman-Rubin ($\hat{R}$), el tamaño muestral efectivo y la inspección de las trazas de las cadenas. Por último, para comparar la importancia relativa de las dos covariables, se calcularon sus coeficientes estandarizados, que cuantifican el cambio esperado en la respuesta asociado a un incremento de una desviación típica en cada covariable.

3. Resultados

3.1. Selección de la distribución y de la codificación de los visitantes

La Tabla 1 compara los modelos lineales (LM) y los modelos lineales generalizados Gamma (GLM), utilizando el número de visitantes como variable continua ($\log V$) o categórica (W). Para

facilitar la comparación, el AIC de los LM se corrigió mediante el jacobiano y se expresó en la escala de la FID. El MSEP se calculó en m^2.

Tabla 1: Comparación de los modelos lineales (LM) y lineales generalizados Gamma (GLM) según la codificación del número de visitantes. Se muestran el R^2 de los LM, la devianza explicada de los GLM, el AIC en la escala de la FID, la diferencia de AIC respecto al modelo con menor valor (ΔAIC) y el error cuadrático medio de predicción por LOOCV (MSEP). En negrita, el modelo seleccionado.

Modelo	Predictor	R^2 / Dev. expl. (%)	AIC	ΔAIC	MSEP (m^2)
LM	$\log V + \sqrt{D}$	64,3	141,83	0,00	185,8
LM	$W + \sqrt{D}$	46,7	149,05	7,22	249,7
GLM Gamma	$\mathbf{\log V + \sqrt{D}}$	**60,2**	**142,74**	**0,91**	**182,8**
GLM Gamma	$W + \sqrt{D}$	39,2	150,65	8,82	245,6

Los resultados favorecen claramente la inclusión del número de visitantes como variable continua. En ambos tipos de modelo, sustituir $\log V$ por el indicador W reduce la variabilidad explicada, aumenta el AIC en más de siete unidades y eleva el MSEP en unos 60–64 m^2. La dicotomización pierde información sobre la intensidad de las visitas, al asignar el mismo valor a colonias con niveles de afluencia muy diferentes.

Entre los modelos con visitantes como variable continua, el LM y el GLM Gamma presentan resultados similares. La diferencia de AIC es de solo 0,91, lo que indica un apoyo relativo similar según este criterio, mientras que el GLM obtiene un MSEP ligeramente inferior (182,8 frente a 185,8 m^2). Los diagnósticos gráficos no muestran desviaciones importantes de los supuestos de linealidad, normalidad y homocedasticidad, ni evidencias de observaciones influyentes en ninguno de los dos modelos (Figuras A4 y A5). Para el LM, las pruebas complementarias tampoco detectan evidencias de falta de normalidad ($p = 0{,}73$) ni de heterogeneidad de varianzas ($p = 0{,}88$) (Tabla B1). Ante un ajuste y una capacidad predictiva equivalentes, se selecciona el GLM Gamma, ya que modela la FID sin transformarla y sus coeficientes se interpretan directamente como efectos multiplicativos sobre la FID media.

3.2. Evaluación de la linealidad mediante GAM

Fijada la distribución Gamma con enlace logarítmico, la Tabla 2 muestra el proceso de ajuste de la dimensión de las bases en el GAM con las covariables en escala original.

Tabla 2: Comparación de GAM Gamma con enlace logarítmico y distintas dimensiones de las bases. k_V y k_D: dimensiones de las bases para visitantes y densidad, respectivamente. edf: grados de libertad efectivos. MSEP: error cuadrático medio de predicción por LOOCV. En el último modelo, la densidad se incluye como término lineal.

Predictor	k_V	k_D	edf $f_1(V)$	edf $f_2(D)$	Dev. expl. (%)	AIC	MSEP (m^2)
$f_1(V) + f_2(D)$	5	5	3,26	1,33	81,2	136,49	281,7
$f_1(V) + f_2(D)$	5	3	3,26	1,29	81,1	136,43	286,1
$f_1(V) + \beta_2 D$	5	–	3,25	lineal	80,0	136,33	233,9

El efecto de los visitantes mostró una clara no linealidad (edf = 3,26), mientras que el de la densidad fue prácticamente lineal (edf = 1,33). Por ello, se redujo la dimensión de la base de la densidad de $k_D = 5$ a $k_D = 3$ y, dado que su efecto seguía siendo casi lineal, se incorporó finalmente como término lineal. Esta simplificación apenas redujo la devianza explicada (del 81,2 al 80,0 %) y produjo el menor AIC y MSEP de los tres modelos.

Los diagnósticos respaldaron la adecuación de los tres modelos. Los edf se mantuvieron por debajo de k' y el *k-index* no indicó insuficiencia de las bases ($p > 0{,}05$, Tabla B2). Tampoco se

observaron problemas de concurvidad, cuyos valores quedaron por debajo de 0,8 en todos los casos (Tabla B3).

3.3. Selección del modelo final: inferencia frecuentista y bayesiana

Aunque el GAM con densidad lineal explica más devianza que el GLM Gamma (80,0 frente a 60,2 %) y presenta un AIC unos 6 puntos menor, su MSEP es un 28 % superior (233,9 frente a 182,8 m^2, Tablas 1 y 2). Esto indica sobreajuste que podría deberse a que el *spline* se adapta a las cinco colonias situadas tras el amplio intervalo sin datos entre 154 y 2643 visitantes. Por ello, se seleccionó el GLM Gamma como modelo final seleccionado.

La Tabla 3 compara las estimaciones del GLM Gamma por máxima verosimilitud y por inferencia bayesiana. Las cadenas de JAGS convergieron adecuadamente, con $\hat{R} < 1{,}1$ y tamaños muestrales efectivos superiores a 100 para todos los parámetros (Figura A6). Las distribuciones a posteriori se muestran en la Figura A7.

Tabla 3: Estimaciones del GLM Gamma con enlace logarítmico para la FID media en función del número de visitantes ($\log V$) y la densidad de parejas ($\sqrt{D}$). Se muestran las estimaciones por máxima verosimilitud con sus intervalos de confianza (IC) del 95 % y las estimaciones bayesianas (medias a posteriori) con sus intervalos de credibilidad (ICr) del 95 %.

Parámetro	Estimación	Inferior 95 %	Superior 95 %
Máxima verosimilitud			
Intercepto	4,535	3,928	5,166
$\log V$	−0,159	−0,223	−0,093
$\sqrt{D}$	−0,080	−0,130	−0,026
Inferencia bayesiana			
Intercepto	4,531	3,875	5,184
$\log V$	−0,158	−0,228	−0,086
$\sqrt{D}$	−0,077	−0,131	−0,019

Ambos métodos proporcionan estimaciones muy similares. Los coeficientes de $\log V$ y $\sqrt{D}$ son negativos, lo que indica que la FID media disminuye al aumentar el número de visitantes y la densidad de parejas. Según el modelo bayesiano, al duplicarse el número de visitantes, la FID media se multiplica por $2^{\beta_1} = 0{,}896$ (ICr del 95 %: 0,854–0,942), lo que supone una reducción aproximada del 10 %, independientemente del número de visitantes inicial. En cambio, el efecto de la densidad depende de su valor de partida debido a la transformación de raíz cuadrada. Por ejemplo, pasar de 100 a 200 parejas por unidad de superficie reduce la FID media aproximadamente un 27 % (ICr del 95 %: 7–42 %). Ambos coeficientes son estadísticamente significativos ($p < 0{,}001$ para $\log V$ y $p = 0{,}008$ para $\sqrt{D}$), y sus intervalos de confianza y credibilidad del 95 % excluyen el cero.

Los coeficientes estandarizados, calculados sobre las covariables en la escala utilizada en el modelo, indican que el número de visitantes tiene un efecto mayor sobre la FID que la densidad (Tabla B4). Un aumento de una desviación típica en $\log V$ se asocia con una reducción aproximada del 43 % en la FID media, frente al 30 % asociado a $\sqrt{D}$. No obstante, el cociente entre ambos efectos presenta un intervalo de credibilidad amplio (0,8–5,6), por lo que la diferencia entre sus magnitudes es incierta con una muestra de 18 colonias.

El modelo explica el 60,2 % de la devianza y predice una menor FID a medida que aumentan los visitantes y la densidad (Figuras 1 y A8). En colonias sin visitas, la FID estimada disminuye de unos 61 m con la menor densidad a 16 m con la mayor. En las colonias con más de 2600 visitantes, se sitúa entre unos 11 y 20 m, incluso con densidades bajas. Las isolíneas muestran que una misma FID puede corresponder a distintas combinaciones de ambas variables. No obstante, las

predicciones para colonias con muchos visitantes y alta densidad son extrapolaciones, ya que no hay observaciones en ese rango.

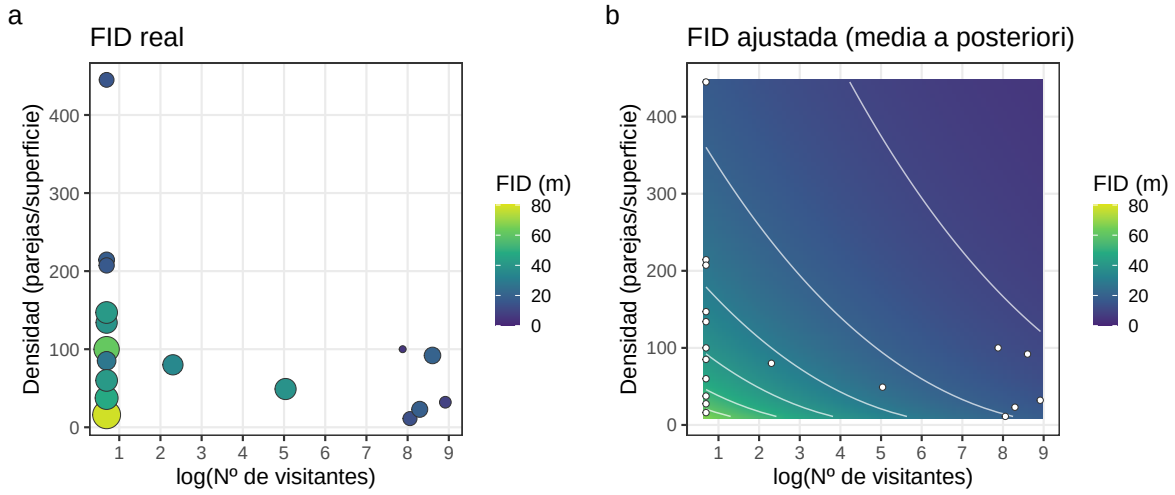


Figura 1: (a) FID media observada por colonia en función del logaritmo del número de visitantes y de la densidad de parejas. El tamaño y el color de los puntos representan la FID. (b) FID media estimada por el GLM Gamma bayesiano (media a posteriori), con isolíneas cada 10 m y las colonias observadas en blanco.

4. Discusión y conclusiones

Los resultados concuerdan con Martínez-Abraín et al. (2008), que también observaron una menor FID media al aumentar el número de visitantes y la densidad de parejas. Este trabajo amplía su enfoque mediante la comparación de distribuciones, codificaciones de los visitantes y modelos más flexibles. El LM y el GLM Gamma mostraron un rendimiento similar, mientras que dicotomizar los visitantes empeoró el ajuste. Aunque los GAM explicaron más devianza, su mayor error predictivo sugiere sobreajuste. Por tanto, se escogió el GLM Gamma frente al LM, modelo base de Martínez-Abraín et al. (2008), por su interpretabilidad y porque modela directamente la FID, sin necesidad de retransformar la respuesta. Los coeficientes estandarizados indican que el efecto de los visitantes es aproximadamente 1,6 veces el de la densidad, aunque esta diferencia es incierta con solo 18 colonias.

La menor FID asociada a un mayor número de visitantes es compatible con una habituación rápida de las gaviotas, mientras que su reducción en colonias densas podría relacionarse con el riesgo de depredación de los nidos por otras gaviotas. Desde el punto de vista de la gestión, las colonias sin visitas regulares serían las más sensibles a la presencia humana. Dado el efecto logarítmico de los visitantes, las primeras visitas producen la mayor reducción de la FID, mientras que las visitas adicionales apenas la modifican en colonias muy frecuentadas. Además, el modelo permite estimar distancias de seguridad equivalentes al doble de la FID, como proponen Martínez-Abraín et al. (2008). Para una densidad de 80 parejas por unidad de superficie, estas serían de unos 84 m en una colonia sin visitas (ICr del 95 %: 63–112 m) y de 25 m con 5000 visitantes (ICr del 95 %: 16–38 m). Por tanto, en lugar de prohibir las visitas, convendría regularlas mediante itinerarios fijos y adaptarlas a la densidad de cada zona.

Este análisis presenta varias limitaciones. Con solo 18 colonias, la capacidad para detectar no linealidades e interacciones es limitada. Además, el valor de 2 visitantes es una imputación, y la ausencia de datos entre 154 y 2643 visitantes y de colonias visitadas con alta densidad obliga a extrapolar. Por último, el uso de medias impide analizar la variabilidad individual, por lo que una extensión natural sería un modelo mixto que incorporase la colonia como efecto aleatorio.

Referencias

Anderson, D. W., & Keith, J. O. (1980). The human influence on seabird nesting success: Conservation implications. *Biological Conservation*, *18*(1), 65-80.

Blumstein, D. T. (2003). Flight-initiation distance in birds is dependent on intruder starting distance. *Journal of Wildlife Management*, *67*(4), 852-857.

Blumstein, D. T. (2006). Developing an evolutionary ecology of fear: how life history and natural history traits affect disturbance tolerance in birds. *Animal Behaviour*, *71*(2), 389-399.

Blumstein, D. T., Anthony, L. L., Harcourt, R., & Ross, G. (2003). Testing a key assumption of wildlife buffer zones: is flight initiation distance a species-specific trait? *Biological Conservation*, *110*(1), 97-100.

Boyle, S. A., & Samson, F. B. (1985). Effects of nonconsumptive recreation on wildlife: a review. *Wildlife Society Bulletin*, *13*(2), 110-116.

Burger, J., & Gochfeld, M. (1991). Human distance and birds: tolerance and response distances of resident and migrant species in India. *Environmental Conservation*, *18*(2), 158-165.

Canty, A., & Ripley, B. D. (2025). *boot: Bootstrap Functions* (Ver. 1.3-32). CRAN. https://CRAN.R-project.org/package=boot

Carney, K. M., & Sydeman, W. J. (1999). A review of human disturbance effects on nesting colonial waterbirds. *Waterbirds*, *22*(1), 68-79.

Fernández-Juricic, E., Vaca, R., & Schroeder, N. (2004). Spatial and temporal responses of forest birds to human approaches in a protected area and implications for two management strategies. *Biological Conservation*, *117*(4), 407-416.

Finney, S., Pearce-Higgins, J., & Yalden, D. (2005). The effect of recreational disturbance on an upland breeding bird, the golden plover Pluvialis apricaria. *Biological Conservation*, *121*(1), 53-63.

Gastwirth, J. L., Gel, Y. R., Hui, W. L. W., Lyubchich, V., Miao, W., & Noguchi, K. (2023). *lawstat: Tools for Biostatistics, Public Policy, and Law* (Ver. 3.6). CRAN. https://CRAN.R-project.org/package=lawstat

Geist, C., Liao, J., Libby, S., & Blumstein, D. T. (2005). Does intruder group size and orientation affect flight initiation distance in birds? *Animal Biodiversity and Conservation*, *28*, 69-73.

Hill, D., Hockin, D., Price, D., Tucker, G., Morris, R., & Treweek, J. (1997). Bird disturbance: improving the quality and utility of disturbance research. *Journal of Applied Ecology*, *34*(2), 275-288.

Ikuta, L. A., & Blumstein, D. T. (2003). Do fences protect birds from human disturbance? *Biological Conservation*, *112*(3), 447-452.

Kellner, K. (2026). *jagsUI: A Wrapper Around 'rjags' to Streamline 'JAGS' Analyses* (Ver. 1.6.3). CRAN. https://CRAN.R-project.org/package=jagsUI

Martínez-Abraín, A., Oro, D., Conesa, D., & Jiménez, J. (2008). Compromise between seabird enjoyment and disturbance: The role of observed and observers. *Environmental Conservation*, *35*(2), 104-108.

McClung, M. R., Seddon, P. J., Massaro, M., & Setiawan, A. (2004). Nature-based tourism impacts on yellow-eyed penguins Megadyptes antipodes: does unregulated visitor access affect fledging weight and juvenile survival? *Biological Conservation*, *119*(2), 279-285.

R Core Team. (2024). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria. https://www.R-project.org/

Roberts, G., & Evans, P. R. (1993). Responses of foraging sanderlings to human approaches. *Behaviour*, *126*(1-2), 29-44.

Stankowich, T., & Blumstein, D. T. (2005). Fear in animals: a meta-analysis and review of risk assessment. *Proceedings of the Royal Society of London Series B*, *272*(1581), 2627-2634.

Wood, S. N. (2025). *mgcv: Mixed GAM Computation Vehicle with Automatic Smoothness Estimation* (Ver. 1.9-4). CRAN. https://CRAN.R-project.org/package=mgcv

Declaración de uso de la inteligencia artificial

En la elaboración de este informe se ha utilizado el asistente de inteligencia artificial Claude (Anthropic) como herramienta de apoyo para mejorar la redacción, revisar la coherencia y consistencia del documento, resolver dudas puntuales sobre el código en R y facilitar la presentación del contenido en LaTeX. La autora ha revisado el documento final y es responsable del análisis realizado, las decisiones metodológicas, la interpretación de los resultados y el contenido del informe.

Anexo A Figuras

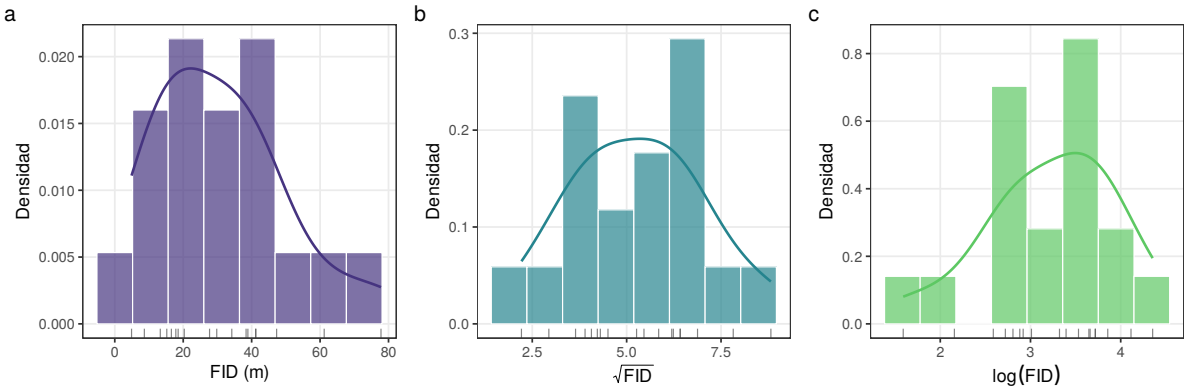
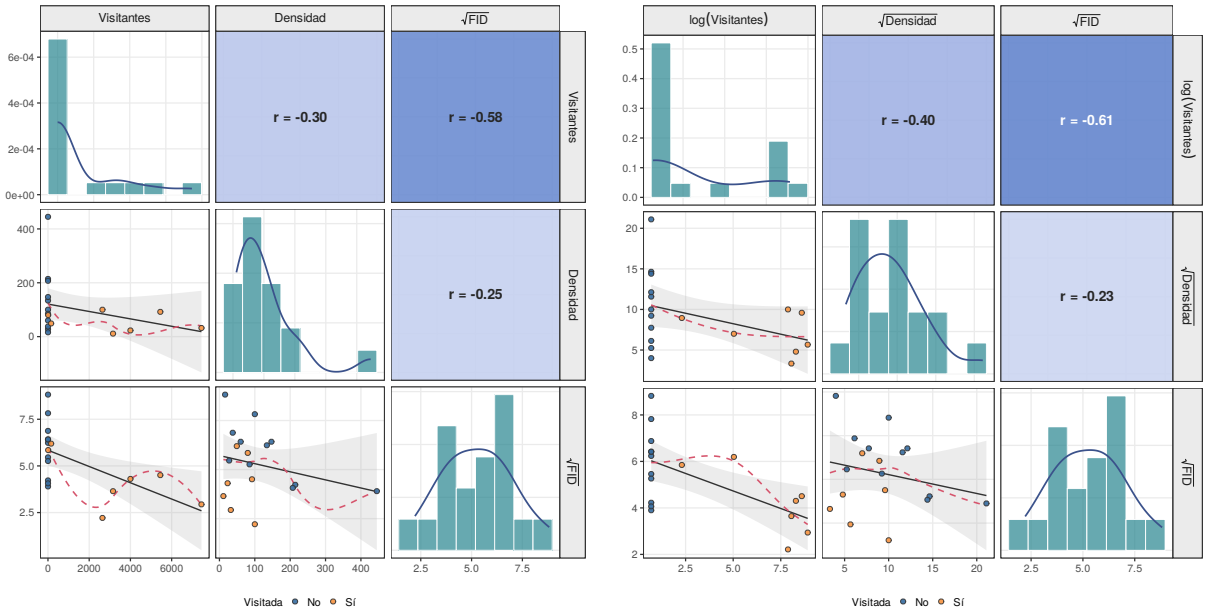


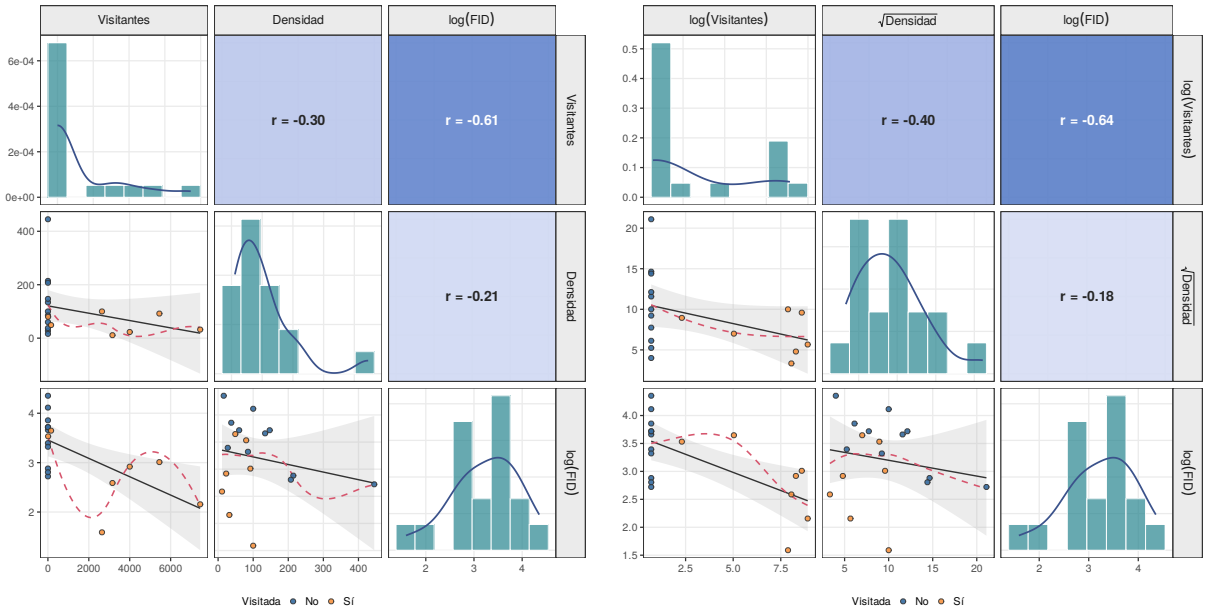
Figura A1: Distribución de la FID media en escala original (a), raíz cuadrada (b) y logarítmica (c). Cada panel muestra el histograma de los datos, la estimación de la densidad kernel (línea continua) y, sobre el eje horizontal, la posición de cada una de las 18 colonias.



(a) Covariables originales.

(b) Covariables transformadas.

Figura A2: Análisis exploratorio de las relaciones entre la raíz cuadrada de la FID media ($\sqrt{\text{FID}}$) y las covariables para el enfoque de regresión lineal, en sus escalas original (a) y transformada (b). En el triángulo inferior, cada punto representa una colonia, coloreada en azul si no recibe visitas y en naranja si recibe visitas. La línea negra representa el ajuste lineal por mínimos cuadrados y la banda gris, su intervalo de confianza del 95 %. La línea discontinua muestra el suavizado LOESS, que permite explorar posibles desviaciones respecto a la linealidad. La diagonal muestra la distribución de cada variable mediante un histograma y una estimación de la densidad kernel. El triángulo superior presenta los coeficientes de correlación de Pearson para cada par de variables.



(a) Covariables originales.

(b) Covariables transformadas.

Figura A3: Análisis exploratorio de las relaciones entre la FID media (FID) y las covariables para el enfoque de modelo lineal generalizado con distribución Gamma y enlace logarítmico, en sus escalas original (a) y transformada (b). En el triángulo inferior, cada punto representa una colonia, coloreada en azul si no recibe visitas y en naranja si recibe visitas. La línea negra representa el ajuste lineal por mínimos cuadrados y la banda gris, su intervalo de confianza del 95 %. La línea discontinua muestra el suavizado LOESS, que permite explorar posibles desviaciones respecto a la linealidad. La diagonal muestra la distribución de cada variable mediante un histograma y una estimación de la densidad kernel. El triángulo superior presenta los coeficientes de correlación de Pearson para cada par de variables.

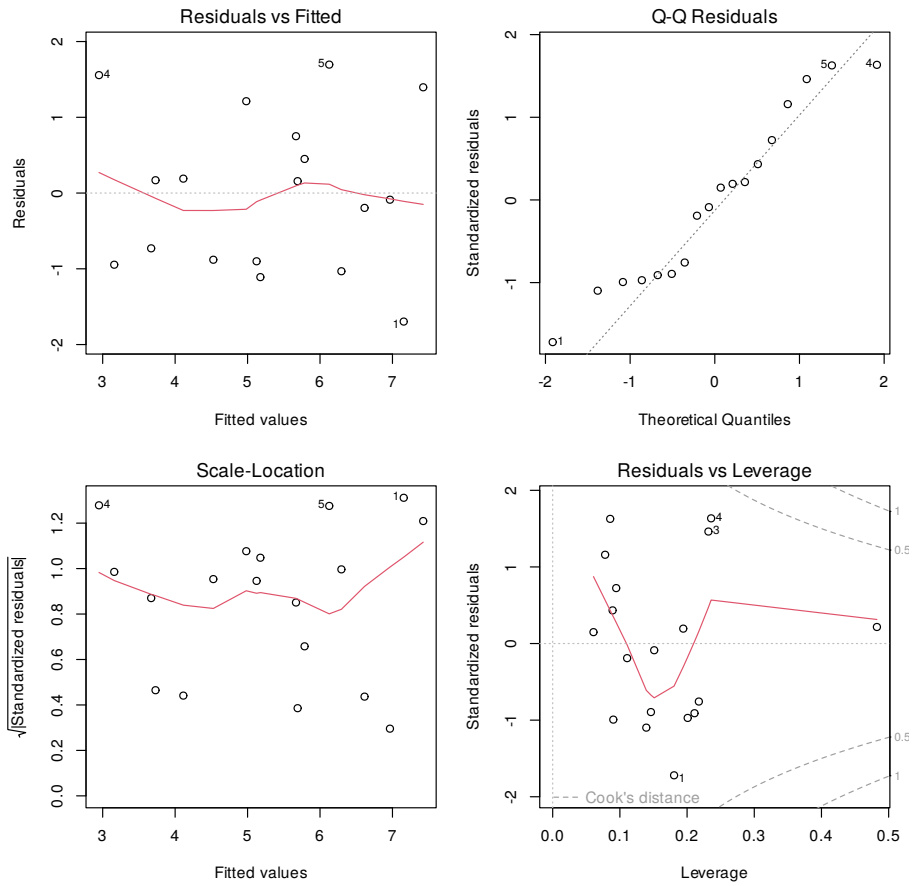


Figura A4: Gráficos de diagnóstico de los residuos del modelo lineal (LM) con el número de visitantes como variable continua. Se muestran los residuos frente a los valores ajustados, el gráfico Q-Q de los residuos estandarizados, el gráfico *scale-location* y los residuos frente al *leverage*, con las curvas de nivel de la distancia de Cook.

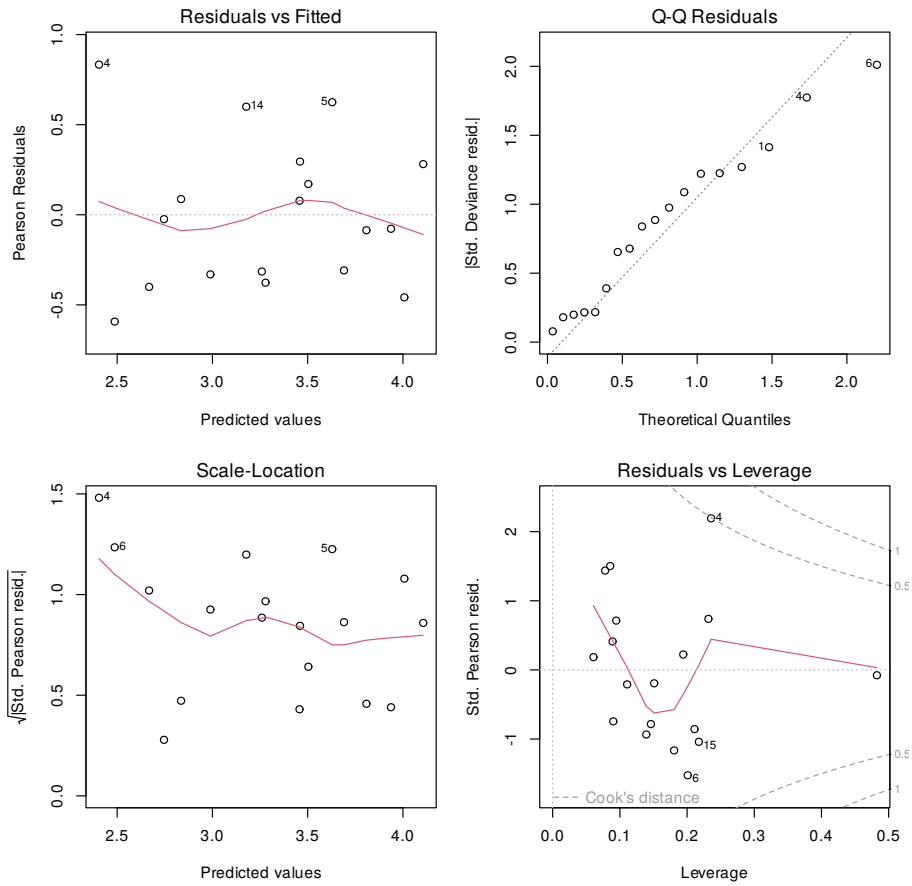


Figura A5: Gráficos de diagnóstico de los residuos del modelo lineal generalizado (GLM) con distribución Gamma y enlace logarítmico, incluyendo el número de visitantes como variable continua. Se muestran los residuos de Pearson frente los valores ajustados, el gráfico Q-Q de los residuos de devianza estandarizados, el gráfico *scale-location* y los residuos estandarizados de Pearson frente al *leverage*, con las curvas de nivel de la distancia de Cook.

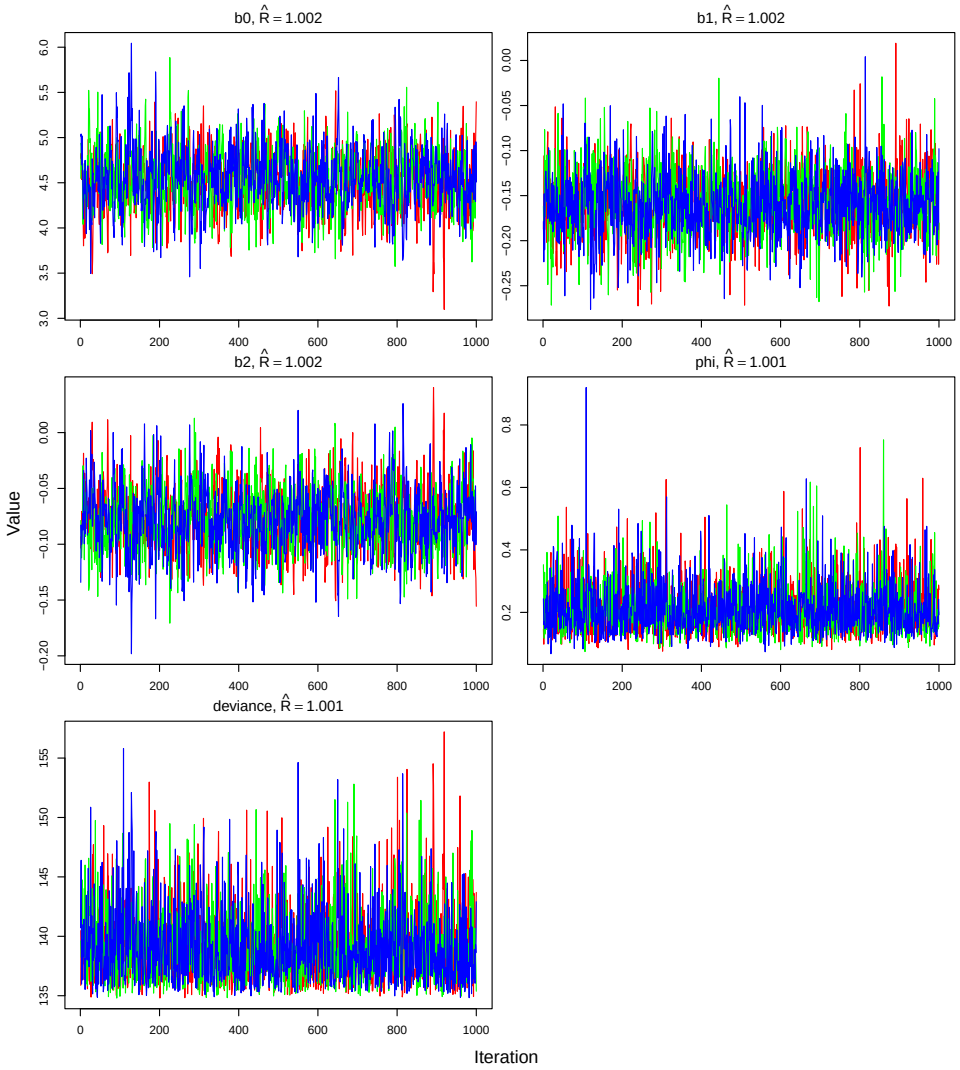


Figura A6: Trazas de las tres cadenas de JAGS para los parámetros del GLM Gamma bayesiano.

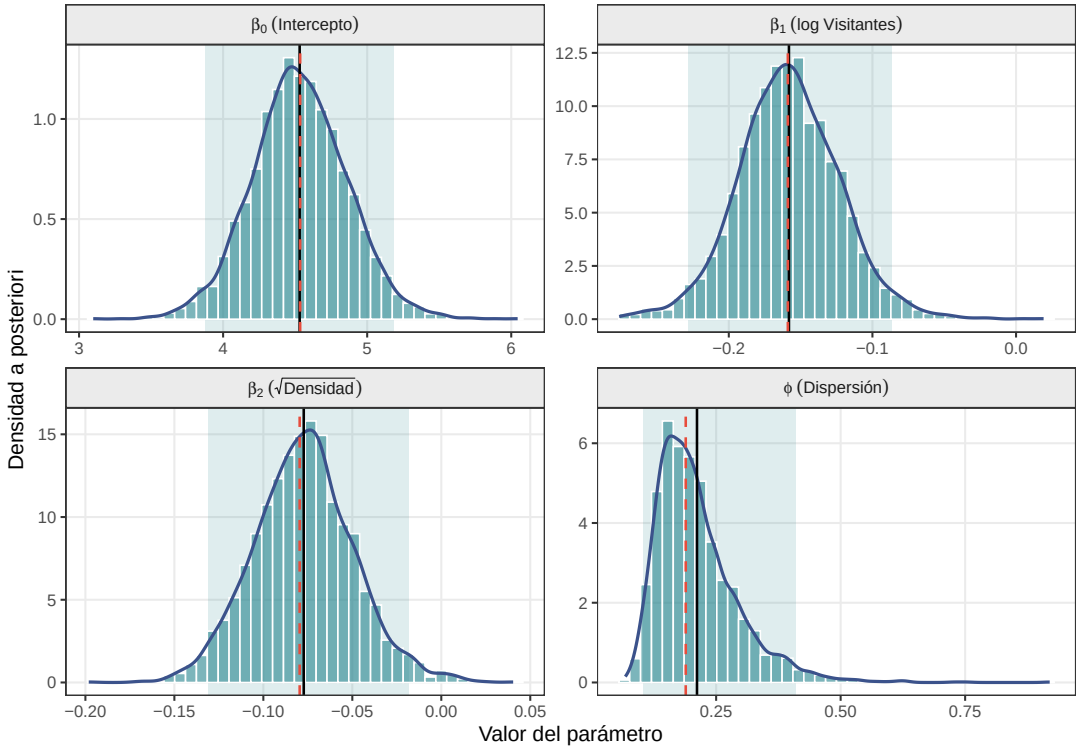


Figura A7: Distribuciones *a posteriori* de los parámetros del GLM Gamma (histograma y densidad), con la media *a posteriori* (línea continua), el intervalo de credibilidad del 95 % (franja sombreada) y la estimación de máxima verosimilitud (línea discontinua roja).

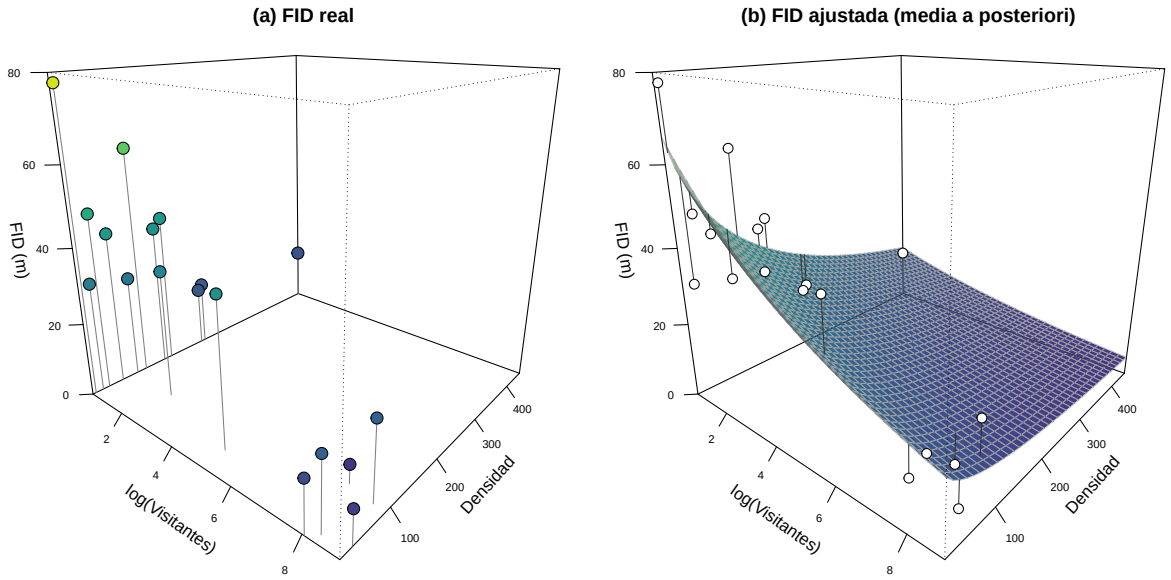


Figura A8: Representación tridimensional de la FID media en función del número de visitantes (escala logarítmica) y de la densidad. (a) FID observada en cada colonia. (b) Superficie de la FID ajustada por el GLM Gamma bayesiano (media *a posteriori*) con las colonias observadas; los segmentos unen cada colonia con la superficie.

Anexo B Tablas

Tabla B1: Pruebas de validación de los residuos de los modelos lineales (LM). La prueba de Kolmogorov-Smirnov evalúa su distribución frente a una distribución t de Student con 14 grados de libertad, mientras que la prueba de Levene evalúa la homogeneidad de varianzas agrupando los residuos estandarizados según los cuartiles de los valores ajustados.

	Kolmogorov-Smirnov		Levene	
Modelo	D	p-valor	$F_{3,\,14}$	p-valor
LM: $\sqrt{Y} \sim \log V + \sqrt{D}$	0,155	0,725	0,219	0,882
LM: $\sqrt{Y} \sim W + \sqrt{D}$	0,153	0,739	0,702	0,567

Tabla B2: Comprobación de la dimensión de las bases de los GAM mediante `k.check()`. k' representa la dimensión efectiva máxima de la base $(k-1)$ y edf los grados de libertad efectivos. El p-valor del *k-index*, obtenido mediante aleatorización, permite evaluar si la dimensión de la base es suficiente.

Modelo	Término	k'	edf	*k-index*	p-valor
$f_1(V) + f_2(D)$	$f_1(V)$	4	3,26	0,78	0,153
	$f_2(D)$	4	1,33	1,07	0,588
$f_1(V) + f_2(D)$	$f_1(V)$	4	3,26	0,77	0,143
	$f_2(D)$	2	1,29	1,07	0,583
$f_1(V) + \beta_2 D$	$f_1(V)$	4	3,25	0,77	0,148

Tabla B3: Concurvidad de los *splines* de los GAM. k' representa el número máximo de grados de libertad de la base $(k-1)$. Para cada término se muestra la concurvidad respecto al resto de términos del modelo según tres medidas: el peor caso (*worst*), las funciones estimadas (*observed*) y una estimación intermedia (*estimate*). Los valores próximos a 1 indican mayor concurvidad, que suele considerarse problemática a partir de 0,8.

Modelo	Término	k'	*Worst*	*Observed*	*Estimate*
$f_1(V) + f_2(D)$	$f_1(V)$	4	0,40	0,17	0,10
	$f_2(D)$	4	0,40	0,14	0,11
$f_1(V) + f_2(D)$	$f_1(V)$	4	0,24	0,15	0,09
	$f_2(D)$	2	0,24	0,14	0,13
$f_1(V) + \beta_2 D$	$f_1(V)$	4	0,13	0,10	0,07

Tabla B4: Coeficientes estandarizados del GLM Gamma final: efecto sobre $\log(\mu)$ de aumentar cada covariable en una desviación típica. $\exp(\beta^*)$: factor por el que se multiplica la FID media. IC: intervalo de confianza; ICr: intervalo de credibilidad.

Variable	β^*	Inferior 95 % IC o ICr	Superior 95 % IC o ICr	$\exp(\beta^*)$
Inferencia por máxima verosimilitud				
$\log V$	−0,554	−0,776	−0,323	0,575
$\sqrt{D}$	−0,356	−0,582	−0,116	0,701
Inferencia bayesiana				
$\log V$	−0,551	−0,796	−0,301	0,576
$\sqrt{D}$	−0,345	−0,586	−0,083	0,708

Anexo C Código R

El código en R utilizado para la modelización y la generación de las figuras incluidas en este informe, así como los datos empleados en el análisis, están disponibles en https://github.com/rcalderonmadrid/informe-gaviotas-FID.